

# Report Statistica Computazionale

Filippo Valente, Luca Oggioni

A.A 2025/2026

## 1 Overview

L'obiettivo del progetto è applicare tecniche di clustering e classificazione a un insieme di brani musicali appartenenti a generi differenti, al fine di verificare se le caratteristiche acustiche quantitative siano in grado di distinguere in modo efficace tra stili musicali diversi. Abbiamo costruito il dataset a partire dai brani di artisti selezionati come rappresentativi di tre macro-generi musicali: Elettronico, Pop e Neoclassico. In particolare, abbiamo scelto di far rappresentare il genere Elettronico da Marc Arcadi-pane, The DJ Producer e Fantasm; il genere Pop da Michael Jackson e Usher; il genere Neoclassico da Ludovico Einaudi e Ólafur Arnalds. Per rendere possibile l'applicazione delle tecniche di clustering e classificazione, è stato necessario costruire preliminarmente un dataset musicale strutturato, contenente feature audio numeriche e informazioni di popolarità dei brani. Una parte rilevante del progetto è quindi dedicata alla raccolta dei dati, alla loro pulizia, standardizzazione e selezione delle variabili più informative. Solo dopo questa fase di preparazione dei dati è possibile applicare metodi statistici per il clustering non supervisionato e per la valutazione della capacità delle feature selezionate di supportare una corretta classificazione supervisionata dei generi musicali.

## 2 Costruzione del dataset e preparazione dei dati

### 2.1 Costruzione del dataset

#### 2.1.1 Raccolta dei dati tramite API

I dati utilizzati nel progetto provengono da due fonti principali: la Spotify Web API e la ReccoBeats API. La prima è stata utilizzata per recuperare informazioni sugli artisti, sugli album e sulle tracce, mentre la seconda ha permesso di ottenere feature audio quantitative e un indicatore di popolarità dei brani. L'uso congiunto di queste due sorgenti consente di associare a ciascun brano sia informazioni descrittive sia variabili numeriche utili per l'analisi statistica.

#### 2.1.2 Impostazione delle funzioni di supporto

La fase iniziale del progetto prevede l'impostazione di un insieme di funzioni adattate a partire da codice open-source <sup>1</sup> reperito su GitHub. Tali funzioni hanno l'obiettivo di automatizzare l'intero processo di costruzione del dataset. In particolare, il codice consente di recuperare automaticamente i brani di ciascun artista, gestire i limiti di richiesta imposti dalle API, scaricare le feature audio e integrare le informazioni provenienti dalle diverse sorgenti in un unico dataset coerente.

#### 2.1.3 Costruzione automatica del dataset

Una volta definite le funzioni di supporto, il dataset viene costruito in modo automatico iterando su un insieme di artisti selezionati. Gli artisti sono stati scelti da noi in modo che rappresentassero i tre generi musicali distinti. I dati ottenuti per ciascun artista vengono progressivamente uniti in un unico dataframe. Eventuali duplicati vengono rimossi, garantendo che ogni osservazione corrisponda a una traccia unica, ottenendo un dataset da 1048 osservazioni.

---

<sup>1</sup>Link: <https://gist.github.com/cjrwebb/6231792aff72abc97b3b94b64341d84c>

Tabella 1: Generi musicali considerati e artisti selezionati per le analisi.

| Genere musicale | Artisti                                   |
|-----------------|-------------------------------------------|
| Elettronico     | Marc Arcadipane, The DJ Producer, Fantasm |
| Pop             | Michael Jackson, Usher                    |
| Neoclassico     | Ludovico Einaudi, Ólafur Arnalds          |

## 2.2 Pulizia e preparazione dei dati

### 2.2.1 Selezione e trasformazione delle variabili

Dopo la costruzione del dataset grezzo, si procede con una fase di iniziale pulizia e parziale selezione delle variabili. In questa fase vengono escluse le variabili e le osservazioni irrilevanti per l'analisi. In particolare, sono state rimosse le variabili qualitative mantenendo esclusivamente le variabili quantitative quali: **popularity**, **acousticness**, **danceability**, **energy**, **liveness**, **loudness**, **tempo**, **valence** e **duration**.

### 2.2.2 Assegnazione delle etichette di genere

A ciascun brano viene assegnata un'etichetta di genere musicale sulla base dell'artista di appartenenza. Questa classificazione consente di associare ogni osservazione a una categoria stilistica omogenea, come Pop, Elettronico o Neoclassico. L'informazione sul genere non viene utilizzata in questa fase per la costruzione del dataset, ma rappresenta un riferimento utile per, successivamente, valutare la bontà di tecniche di Clustering non supervisionate e per adottare tecniche di Classification supervisionate.

### 2.2.3 Standardizzazione delle variabili e analisi descrittiva

Le variabili numeriche selezionate sono state standardizzate tramite Z-score, ottenendo distribuzioni con media nulla e varianza unitaria. Questo passaggio è necessario poiché le feature considerate presentano scale di misura molto differenti. Dal punto di vista della dispersione, si osservano intervalli di variazione differenti tra le variabili. Ad esempio, la popolarità assume valori compresi approssimativamente tra  $-1.47$  e  $3.13$ , mentre la durata dei brani presenta un range più ampio, con valori massimi superiori a 25 in unità standardizzate. Anche variabili acustiche come tempo e loudness mostrano valori estremi, riflettendo l'elevata eterogeneità stilistica del dataset. La standardizzazione consente di rendere tali differenze comparabili, evitando che le feature con maggiore variabilità dominino le analisi successive.

### 2.2.4 Analisi delle Componenti Principali (PCA) e selezione delle variabili

Per individuare un sottoinsieme compatto di variabili informative, è stata applicata un'Analisi delle Componenti Principali (PCA) alle feature numeriche standardizzate. La PCA è utilizzata come strumento esplorativo per analizzare la struttura di correlazione tra le variabili e guidare la selezione delle feature più rappresentative. L'analisi dei *loadings* consente di identificare le variabili con il contributo maggiore alla definizione delle diverse dimensioni latenti del dataset. A tal fine, sono state considerate le prime **sei componenti principali**, le quali spiegano complessivamente il **94.75%** della varianza totale. Per ciascuna componente è stata selezionata la variabile originale con il contributo maggiore in valore assoluto. L'associazione risultante è stata la seguente:

|                 |                     |                 |                   |                 |                 |
|-----------------|---------------------|-----------------|-------------------|-----------------|-----------------|
| <b>Comp. 1:</b> | <b>acousticness</b> | <b>Comp. 2:</b> | <b>popularity</b> | <b>Comp. 3:</b> | <b>duration</b> |
| <b>Comp. 4:</b> | <b>tempo</b>        | <b>Comp. 5:</b> | <b>popularity</b> | <b>Comp. 6:</b> | <b>valence</b>  |

Poiché la variabile **popularity** è risultata la determinante principale per due diverse componenti (la 2 e la 5), le duplicazioni sono state rimosse, ottenendo un insieme finale di **cinque variabili distinte**.

### 3 Model-Based Clustering

L'obiettivo del clustering è individuare eventuali strutture latenti nel dataset musicale, valutando se i brani si organizzino spontaneamente nei tre gruppi nello spazio delle variabili quantitative selezionate. Il clustering viene qui impiegato in assenza di informazione sulle etichette di genere, con lo scopo di analizzare la struttura intrinseca dei dati e il grado di coerenza tra tale struttura e i generi musicali considerati. L'analisi è stata condotta utilizzando esclusivamente le cinque variabili individuate come più informative nella fase di PCA. Per il clustering è stato adottato un approccio *model-based*, basato su *Gaussian Mixture Models*.

#### 3.1 Risultato del Clustering

Il clustering dei brani è stato effettuato mediante la funzione `Mclust` della library `mclust`, che implementa un approccio di *model-based clustering* basato su Gaussian Mixture Models, stimati tramite l'algoritmo Expectation-Maximization (EM). L'algoritmo EM consente di stimare iterativamente i parametri delle componenti gaussiane e le probabilità di appartenenza di ciascuna osservazione ai diversi cluster. La funzione `Mclust` permette inoltre la selezione automatica della struttura delle matrici di covarianza e del modello più appropriato tramite il criterio BIC. In questo caso, il modello che fornisce il miglior compromesso tra qualità dell'adattamento e complessità risulta essere caratterizzato da una delle parametrizzazioni più complesse, ossia quella di tipo VVI, che assume una matrice di covarianza diagonale con volume e forma liberi di variare per ciascun cluster. Si osserva inoltre che anche adottando il criterio ICL, il modello selezionato risulta essere ancora di tipo VVI. Il numero di cluster è stato fissato a priori pari a  $G=3$  all'interno della funzione `Mclust`, in quanto noto il numero di gruppi presenti nel dataset, coerentemente con i tre generi musicali considerati.

#### 3.2 Valutazione della bontà del clustering

##### 3.2.1 Criteri indipendenti dalle etichette

La **distanza di Kullback–Leibler simmetrizzata** tra i cluster è riassunta nella seguente matrice:

|             | Pop     | Neoclassico | Elettronico |
|-------------|---------|-------------|-------------|
| Pop         | 0       | 210.97      | 4058.87     |
| Neoclassico | 210.97  | 0           | 23894.18    |
| Elettronico | 4058.87 | 23894.18    | 0           |

La misura di **incertezza** fornita dal modello presenta il seguente summary:

$$\min = 0, \quad \text{median} = 0.00015, \quad \text{mean} = 0.012, \quad \text{max} = 0.497.$$

L'**entropia** delle probabilità a posteriori, risulta essere uguale a:

$$EN(\hat{z} | Y) = - \sum_{i=1}^m \sum_{j=1}^K \hat{z}_{ij} \log(\hat{z}_{ij}) = 33.8$$

Nel complesso, le tre misure risultano coerenti tra loro. La distanza di Kullback–Leibler simmetrizzata evidenzia una netta separazione tra i cluster Neoclassico ed Elettronico, mentre il cluster Pop occupa una posizione intermedia. I valori molto contenuti di uncertainty e il valore dell'entropia, molto contenuto rispetto al massimo teorico  $m \log K = 1151.346$ , indicano che le probabilità a posteriori sono fortemente concentrate e che il clustering ottenuto risulta complessivamente molto affidabile.

##### 3.2.2 Criteri basati sulle etichette

I risultati numerici del confronto tra i cluster stimati e i generi musicali reali sono riportati nella Tabella 2 e nella Tabella 3. L'accuracy pari a 0.851, corrispondente a un Classification Error Rate del 14.9%, indica che la maggior parte dei brani viene assegnata al cluster corretto. Il valore dell'Adjusted Rand Index (ARI), pari a 0.601, misura una similarità moderata tra le due partizioni considerate, quella prodotta dal clustering e quella basata sui generi musicali reali. L'analisi per classe evidenzia comportamenti differenziati tra i generi musicali. Il cluster Pop risulta quello identificato in modo

Tabella 2: Confusion matrix

| Cluster stimato \ Genere reale | Elettronico | Pop | Neoclassico |
|--------------------------------|-------------|-----|-------------|
| Elettronico                    | 147         | 0   | 0           |
| Pop                            | 81          | 366 | 70          |
| Neoclassico                    | 1           | 4   | 379         |

Tabella 3: Metriche globali di valutazione del clustering

| Misura di bontà                 | Valore |
|---------------------------------|--------|
| Accuracy                        | 0.851  |
| Classification Error Rate (CER) | 0.149  |
| Adjusted Rand Index (ARI)       | 0.601  |

più netto, con un'elevata capacità nel riconoscere correttamente i brani appartenenti a tale genere, accompagnata tuttavia da una maggiore propensione ad includere anche brani provenienti dagli altri generi. Il cluster Elettronico mostra invece una struttura più selettiva, assegnando esclusivamente brani con caratteristiche fortemente coerenti con il genere, a fronte di una maggiore difficoltà nel catturare la totalità delle sue osservazioni. Il cluster Neoclassico risulta ben isolato, presentando un'elevata coerenza interna e una separazione marcata rispetto agli altri generi. Nel complesso, i risultati indicano che il modello è in grado di distinguere in modo efficace tra i tre generi musicali considerati, identificando correttamente il genere Neoclassico e il genere Elettronico come due estremi ben separati nello spazio delle feature, e il genere Pop come un gruppo centrale, caratterizzato da proprietà intermedie rispetto agli altri due.

### 3.2.3 Valutazione Grafica

Per la valutazione grafica, la Figura 1 pone a confronto la classificazione reale (a) con il raggruppamento ottenuto tramite model-based clustering (b). La proiezione è stata effettuata nello spazio delle variabili **acousticness** e **tempo** (esprese in unità standardizzate): dall'analisi della matrice completa degli scatterplot, queste risultano infatti essere le feature con il maggiore potere discriminante tra i gruppi. Nel grafico (b), i punti neri evidenziano i brani classificati erroneamente dal modello rispetto alle etichette reali.




Figura 1: Confronto tra classificazione reale e clustering stimato

Dal confronto emerge che i principali errori dell'algoritmo si concentrano nelle regioni di sovrapposizione tra i gruppi. In particolare, il modello tende a commettere errori sui brani “borderline”, caratterizzati da valori intermedi delle feature, mentre risulta molto efficace nel riconoscere e separare le tre strutture principali del dataset. I cluster associati ai generi Neoclassico ed Elettronico appaiono infatti ben definiti e coerenti, a conferma della capacità del modello di catturare la struttura latente dei dati.

## 4 Supervised Classification

Dopo aver esplorato la struttura latente dei dati tramite clustering non supervisionato, l'analisi si è svolta sulla classificazione supervisionata. L'obiettivo è addestrare un modello statistico in grado di predire il genere musicale di un brano (Elettronico, Pop o Neoclassico) basandosi sulle feature acustiche standardizzate. Per questa fase, il dataset è stato suddiviso casualmente in due sottoinsiemi indipendenti: un *training set* (composto da 800 osservazioni) utilizzato per la selezione e l'addestramento del modello, e un *test set* (248 osservazioni) riservato esclusivamente alla valutazione finale delle performance.

### 4.1 Variabili

Mentre per il clustering è stato necessario ridurre la dimensionalità per evitare rumore nell'analisi, per la fase di classificazione supervisionata si è scelto di reintrodurre il set completo di variabili standardizzate. Avendo a disposizione le etichette reali, il classificatore gaussiano è in grado di gestire la maggiore dimensionalità e sfruttare anche le variabili escluse precedentemente.

### 4.2 Selezione del Modello

La selezione del miglior classificatore è stata effettuata utilizzando la libreria `Rmixmod`. Abbiamo scelto di escludere i modelli che assumono proporzioni fisse perché, in un contesto reale, è molto difficile trovare generi musicali che abbiano esattamente lo stesso numero di brani a disposizione. Successivamente, per individuare la struttura di covarianza ottimale, è stata eseguita una procedura iterativa (100 iterazioni) valutando le performance in base all'errore di Cross-Validation (CV) e al criterio BIC. Dall'analisi dei risultati sono emersi tre profili principali di modelli candidati:

Tabella 4: Confronto tra i modelli candidati: parsimonia vs accuratezza.

| Modello                | Famiglia | Accuratezza Media | Parametri | Note                          |
|------------------------|----------|-------------------|-----------|-------------------------------|
| <b>Gaussian_pk_L_C</b> | EEE      | <b>0.940</b>      | <b>74</b> | <b>Vincitore (Parsimonia)</b> |
| Gaussian_pk_L_Dk_A_Dk  | -        | 0.940             | 90        | Più complesso, stessa resa    |
| Gaussian_pk_Lk_Ck      | VVV      | 0.941             | 164       | Rischio Overfitting           |

Il modello **Gaussian\_pk\_L\_C** (famiglia EEE: volumi uguali, forme uguali, orientamenti uguali) è stato selezionato come vincitore per i seguenti motivi:

1. **Stabilità:** è converso alla soluzione ottimale con la frequenza più alta (41 vittorie su 100 iterazioni).
2. **Parsimonia:** a parità di accuratezza media (0.940) rispetto al primo sfidante, utilizza 16 parametri in meno.
3. **Prevenzione dell'Overfitting:** il modello più complesso (164 parametri) offriva un miglioramento irrisorio (+0.1%) a fronte di un raddoppio dei gradi di libertà.

**Caratterizzazione teorica del modello:** Dal punto di vista statistico, il modello vincitore **Gaussian\_pk\_L\_C** (famiglia EEE) corrisponde strutturalmente a una **Linear Discriminant Analysis (LDA)**. Esso assume infatti l'omoschedasticità tra i gruppi, ovvero che tutte le classi condividano la stessa matrice di covarianza ( $\Sigma_k = \Sigma$ ), pur mantenendo proporzioni delle classi variabili ( $p_k$ ). L'intera

procedura di selezione si basa sul framework **EDDA** (Eigenvalue Decomposition Discriminant Analysis), implementato in **Rmixmod**. Tale metodo decompone la matrice di covarianza spettrale secondo la formula:

$$\Sigma_k = \lambda_k D_k A_k D_k^T$$

**Giustificazione metodologica finale:** La decisione di fissare la struttura **Gaussian\_pk.L.C** per le fasi successive di Validazione Monte Carlo e predizione sul Test Set risponde al principio di parsimonia. Stiamo verificando la stabilità della migliore struttura parsimoniosa individuata, evitando di adattarci al rumore statistico specifico del training set.

### 4.3 Validazione Monte Carlo

Per verificare che le prestazioni del modello selezionato non fossero dovute a una fortuita partizione dei dati, è stato eseguito uno "Stress Test" tramite **Monte Carlo Cross-Validation**. Il modello **Gaussian\_pk.L.C** è stato sottoposto a 100 iterazioni di una 10-Fold Cross Validation (per un totale di 1000 addestramenti su partizioni diverse).




Figura 2: Validazione Monte Carlo: Distribuzione della Density dell'accuratezza su 100 iterazioni. La curva stretta e centrata attorno a 0.94 indica un'elevata stabilità del modello.

I risultati statistici (Media  $\approx 0.940$  con bassa deviazione standard) confermano che il modello è stabile e generalizza bene.

### 4.4 Performance sul Test Set e Analisi degli Errori

Dopo la validazione, il modello finale è stato addestrato sull'intero training set e applicato al **test set** indipendente. L'accuratezza globale ottenuta è pari a **0.9476** ( $\approx 94.8\%$ ), confermando l'ottima capacità discriminante delle variabili.

#### 4.4.1 Matrice di Confusione

La matrice di confusione riportata di seguito mostra un alto tasso di corretta classificazione.

Tabella 5: Matrice di Confusione sul Test Set.

| Reale \ Predetto | Elettronico | Pop | Neoclassico |
|------------------|-------------|-----|-------------|
| Elettronico      | 47          | 1   | 1           |
| Pop              | 0           | 100 | 7           |
| Neoclassico      | 4           | 1   | 87          |

#### 4.4.2 Analisi visiva e qualitativa degli errori

L'analisi degli errori si è concentrata sul circa 5% di brani mal classificati. Attraverso la visualizzazione grafica nello spazio delle feature (Figura 3), è stato possibile identificare le osservazioni problematiche.




Figura 3: Scatter plot sul Test Set (Popolarità vs Energia). I punti cerchiati rappresentano le osservazioni classificate erroneamente dal modello ed il colore del centro rappresenta il gruppo in cui è stato assegnato.

## 5 Conclusioni

In conclusione, i risultati mostrano che le caratteristiche acustiche quantitative sono informative per la distinzione tra i generi musicali considerati. Sia l'approccio di clustering non supervisionato sia quello di classificazione supervisionata evidenziano una buona capacità di separare i tre generi nello spazio delle variabili, confermando che tali feature riescono a catturare differenze strutturali rilevanti tra gli stili musicali. Nel complesso, l'analisi supporta l'efficacia di metodi statistici basati su feature quantitative per lo studio e la caratterizzazione dei generi musicali.